SOLUCIÓN DE IA LOCAL · MVP

Inteligencia artificial local para la Dirección de Distribución y Ventas

Un centro de conocimiento documental que responde con evidencia, dentro de su infraestructura y sin enviar un solo dato a internet.

PREPARADO PARA
Dirección de Distribución y Ventas

CLIENTE
Empresa energética de nivel nacional

OFERENTE
Innovainteligente

innova inteligente.com

El conocimiento está, pero no se puede consultar

La Dirección decide con información que existe, pero dispersa en contratos, reportes, actas, PDF y archivos físicos. Cada consulta depende de quién la tenga o de cuánto tarde en buscarla.

LA PREGUNTA DE GERENCIA

“¿Cómo cerró el despacho de Oriente en septiembre frente a la meta y qué contratos se vieron afectados?”

HOY, PARA RESPONDER

Hay que ubicar el reporte correcto, confirmar la versión vigente, cruzar el contrato y pedirle el dato a quien lo trabajó.

RESULTADO

Respuestas distintas, sin cita única y sin trazabilidad para la auditoría.

ERP/CRM · Archivos · Correo · Papel

≈ 5 TB de documentos, reportes, PDF y archivos físicos según el levantamiento preliminar.

La información existe. Lo que falta es un acceso único, verificable y en segundos.

01

Dispersión documental

Contratos, reportes, actas y PDF conviven en carpetas, correos, equipos y papel, sin un índice único.

Cada área guarda su propia versión.

02

Dependencia de personas

El conocimiento crítico vive en pocas personas; si no están, la respuesta se detiene.

El reemplazo no está documentado.

03

Tiempo de respuesta

Una pregunta de gerencia tarda días en convertirse en una respuesta verificable y trazable.

La reunión se decide sin el dato.

04

Riesgo y confidencialidad

La información estratégica no puede salir a la nube, y el papel se deteriora sin ser auditable.

La nube está fuera de discusión.

> “Lo que no se puede consultar, no se puede gobernar.”

Las cifras se cuantifican en la Fase 0 · diagnóstico

Un cerebro documental que vive en su sede

Instalamos un servidor de IA local que lee, ordena y conecta la documentación de la Dirección; responde en lenguaje natural con citas verificables y no envía un solo dato a internet.

01 · COMPRENDE

Lee lo que la empresa ya tiene

OCR e IDP sobre PDF, escaneos y papel; clasifica, extrae metadatos y detecta duplicados.

PDF · escaneos · papel

02 · ORGANIZA

Un índice único y semántico

Base vectorial con búsqueda híbrida: significado + palabras clave + filtros por área, fecha y clasificación.

Qdrant · índice híbrido

03 · RESPONDE

Copiloto con evidencia

Modelo local Qwen3.5 con RAG, reranking y citas de documento, página y fecha en cada respuesta.

Citas · confianza alta

04 · VIGILA

Dashboard de operación y de IA

Ventas, despacho, inventario, clientes, documentos, calidad de las respuestas y salud del sistema.

KPIs · alertas · auditoría

Por qué local

- **Confidencialidad**
  El dato no sale del perímetro de la empresa.
- **Disponibilidad**
  Opera sin internet y sin depender de terceros.
- **Control**
  La empresa es dueña del dato, del índice y del modelo.
- **Costo predecible**
  Sin cobro por token ni por consulta.
- **Soberanía tecnológica**
  Componentes abiertos, auditables y reemplazables.

100 % on-premise · 0 llamadas externas

SERVICIOS ACTIVADOS: 02 · IDP | 04 · Integración | 07 · MVP | 11 · Diagnóstico | 12 · Hoja de ruta | 13 · Gobernanza | 14 · Capacitación

Del documento a la respuesta, por capas

Una arquitectura modular y auditable que se integra con lo que ya existe y no obliga a reemplazar sistemas.

01
Fuentes
- ERP y CRM
- Servidores de archivos
- Correo y PDF
- Archivo físico

→ documentos y páginas

02
Ingesta
- OCR y layout
- Clasificación
- Metadatos
- Deduplicación

→ texto y metadatos

03
Conocimiento
- Almacén documental
- Qdrant
- Embeddings
- Índice híbrido

→ vectores y fragmentos

04
Inteligencia
- Qwen3.5 local
- RAG
- Reranking
- Citas validadas

→ respuesta citada

05
Experiencia
- Copiloto web
- API interna
- Dashboard
- Alertas

→ decisiones

06
Gobierno
- Roles (RBAC)
- Auditoría
- Cifrado y respaldo
- Monitoreo

→ control y trazabilidad

Local-first
Sin dependencia de nube ni llamadas externas.

Modular
Escala por etapas sin rehacer la base.

Trazable
Cada respuesta con su fuente y su página.

Interoperable
API y conectores con los sistemas existentes.

PASO 1
Pregunta en lenguaje natural

PASO 2
Búsqueda híbrida en el índice

PASO 3
Reranking de los fragmentos

PASO 4
Respuesta con citas validadas

100 %
Del dato permanece en la infraestructura de la empresa.

0
Llamadas a servicios externos; opción de operación aislada.

TRAZA
Cada respuesta queda vinculada a su documento y su página.

Qué podrá preguntar la Dirección y qué obtendrá

Respuestas en segundos, con la fuente exacta y el fragmento citado. Nada de cajas negras: la evidencia se puede abrir y auditar.

01
Contratos
Cláusulas, vigencias, penalidades y volúmenes comprometidos.

«Resume las penalidades del contrato X»

02
Despacho y ventas
Cliente, producto, terminal y período; desviaciones frente al plan.

«Compara despacho vs. plan por terminal»

03
Reportes
Hallazgos, incidencias y planes de acción de períodos anteriores.

«Qué incidencias afectaron Oriente»

04
Cumplimiento
Documentos faltantes, vencimientos y soportes de auditoría.

«Qué documentos faltan para auditoría»

05
Archivo físico
Digitalización y búsqueda de expedientes históricos.

«Busca el expediente del cliente Y»

06
Briefs ejecutivos
Preparación de reuniones con citas en minutos, no en días.

«Brief para la reunión del comité»

EJEMPLO DE CONSULTA · GERENCIA DE DESPACHO

¿Cómo cerró el despacho de Oriente en septiembre frente a la meta y qué contratos se vieron afectados?

> El volumen despachado alcanzó 94 % de la meta. La desviación se concentra en Puerto La Cruz por el retraso de dos buques; los contratos D-2026-114 y D-2026-087 registran ajustes.

Fuente 1 · Informe de despacho septiembre · p. 12
Fuente 2 · Acta de comité 12/10 · p. 3
Fuente 3 · Contrato D-2026-114 · p. 8

6,2 s · 3 fuentes · confianza alta · original enlazado

Qué garantiza cada respuesta

Anclaje	Se limita a los fragmentos recuperados.
Cita	Se verifica contra el documento original.
Sin evidencia	Si no consta, lo dice; no inventa.

PREGUNTAS SUGERIDAS

Resume el contrato X · Despacho vs. plan · Documentos de auditoría

Documento original enlazado
Fecha y versión del archivo
Página y sección exactas
Confianza alta · trazable

Cada respuesta incluye documento, página o sección, fecha, nivel de confianza y enlace al original. El ejemplo es ilustrativo; las cifras reales dependen de la base documental.

El pulso de la operación y de la IA, en una sola pantalla

Ventas, despacho, inventario, clientes, contratos, precios, documentos, copiloto, observatorio de almacenes, flota y yacencias: una sola vista para decidir.



Qué entregamos y con qué equipo

Un producto mínimo viable en 16–24 semanas (incluida la adquisición), con alcance cerrado y una estación AMD Strix Halo dimensionada para modelos de 30B a 235B.

1. **Estación de IA local.** GMKtec EVO-X5 Pro: PRO 495, 192 GB LPDDR5X, 2 TB NVMe, 2×10 GbE; UPS y respaldo.
2. **Ingesta del lote piloto.** 1.500–3.000 documentos (10.000–20.000 páginas) con OCR, clasificación y metadatos.
3. **Base vectorial y motor RAG.** Qdrant, búsqueda híbrida, reranking y citas validadas.
4. **Copiloto para 10–20 usuarios.** Roles y permisos, interfaz web y API para sistemas internos.
5. **Dashboard v1, gobernanza y capacitación.** Manual, dos talleres y transferencia al equipo.

192 GB permiten el modelo 122B + embeddings + reranker en memoria.
273 GB/s sostienen 78–100 tok/s estimados en el modelo interactivo.
2×10 GbE + DASH dan perfil de servidor, no de escritorio.

El lote documental y el alcance exacto se cierran en la Fase 0 con la Dirección.

ESTACIÓN IA LOCAL

192 GB

LPDDR5X-8533 · 273 GB/s · 160 GB para GPU

196 GB no existe como SKU oficial

APU	Ryzen AI Max+ PRO 495 · 16C/32T
GPU	Radeon 8065S · 40 CU
NPU	XDNA 2 · 55 TOPS
Almacenamiento	2 TB NVMe · 4 ranuras M.2 (1 + 3)
Red	2×10 GbE · AMD DASH
Energía	Fuente 330 W · 1.051,2–1.226,4 kWh/año
Sistema	Windows 11 Pro · Linux/Ubuntu
Garantía	1 año + 2 de componentes

Incluye UPS, respaldo externo, instalación y red. 2 TB locales para el lote piloto; los ~5 TB se montan en NAS/ almacenamiento corporativo.

PRECIO OFICIAL

USD 6.799,00

192 GB + 2 TB
sin flete, aranceles ni IVA

CRITERIOS DE ACEPTACIÓN

- 100 % lote sin pérdida
- Citas ≥ 95 %
- Latencia < 10 s
- Operación offline

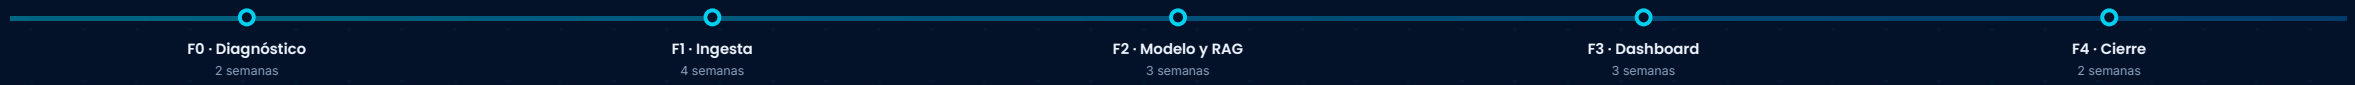
MODELOS LOCALES

- Qwen3.5-35B-A3B · interactivo
- Qwen3.5-122B-A10B · análisis

262.000 tokens · Apache-2.0 · DeepSeek V4.1 no cabe en 192 GB.

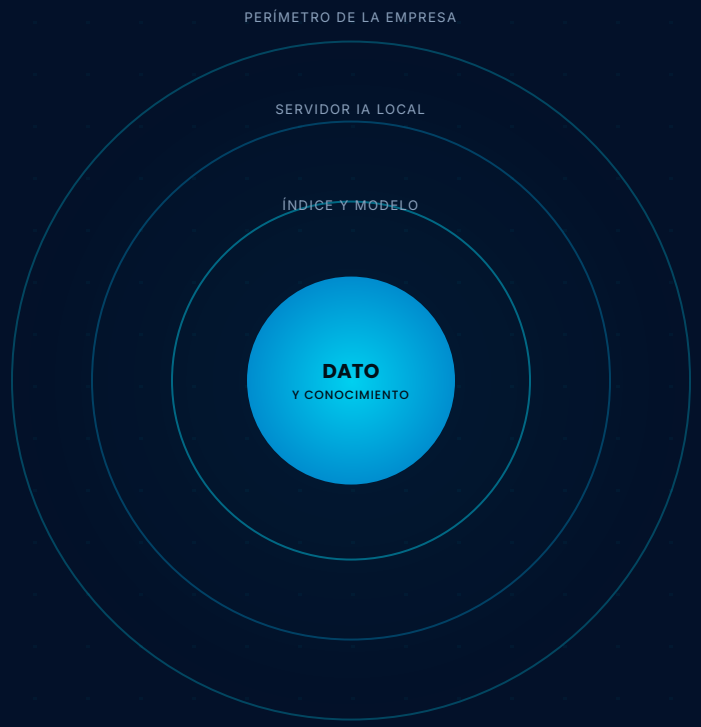
SALVEDAD TÉCNICA

MVP/piloto: los ~5 TB y la concurrencia nacional exigen clúster en fase 2. Mini-PC profesional, no servidor certificado 24/7; UPS y monitoreo.



La IA opera dentro del perímetro; el conocimiento es de la empresa

El dato, el índice y el modelo viven en la infraestructura de la empresa. Sin llamadas externas, con roles, auditoría y respaldo.



100 % on-premise
Sin salida a internet; opción de operación aislada (air-gap).

Roles y permisos
RBAC e integración con LDAP/Active Directory.

Cifrado y auditoría
Cifrado en reposo y tránsito; registro de consultas y accesos.

Respaldo 3-2-1
Copia local, externa y fuera de línea; plan de continuidad.

Gobernanza del dato
Clasificación, retención, calidad y trazabilidad.

Ética y sesgos
Revisión de respuestas, criterios de uso y documentación del modelo.

Continuidad operativa
UPS, monitoreo térmico y segundo nodo opcional.

Cumplimiento
Contratos, políticas de uso y validación jurídica del marco aplicable.

SIN TELEMETRÍA · SIN LLAMADAS EXTERNAS · SIN ENTRENAMIENTO CON DATOS DEL CLIENTE

Propiedad: el dato y el conocimiento son del cliente; Innovainteligente conserva su metodología y componentes reutilizables, con licencia de uso. Confidencialidad contractual y validación jurídica del marco aplicable.

QUÉ QUEDA REGISTRADO

Usuario y rol
Quién consultó y con qué permisos.

Consulta y fuentes
Qué preguntó y qué documentos sustentaron la respuesta.

Documento y versión
Página, fecha y hash del archivo citado.

Una inversión clara, sin costo por token

MVP estimado en **USD 64.967,38** (cifras orientativas, con logística estimada). Primer año: **USD 73.607,38**. Horas y tarifas propuestas, a validar en la Fase 0.

COMPONENTE	DETALLE	HORAS	USD
1. Hardware	Estación GMKtec EVO-X5 Pro 192 GB + 2 TB.	—	6.799,00
2. Logística e importación	Flete, seguro, aranceles e IVA (reserva 25 %; a cotizar).	—	2.212,25
3. Asesoría y gobernanza	Diagnóstico, casos de uso, hoja de ruta, políticas, 2 talleres.	160	8.800,00
4. Programación e integración	IDP/OCR, RAG, Qdrant, dashboard, API, RBAC y respaldo.	560	22.400,00
5. Adecuación de modelos	Evaluación, prompts, LoRA/QLoRA, cuantización y citas.	180	10.800,00
6. Gestión y QA	Dirección de proyecto, pruebas, aceptación y documentación.	120	6.000,00
7. Complementos	NAS 5 TB, UPS y respaldo externo (estimado).	—	2.050,00
Subtotal		1.020	59.061,25
Contingencia 10 %		—	5.906,13
TOTAL MVP · cifras orientativas		**1.020**	**64.967,38**

BASE DEL CÁLCULO

1.020 horas de esfuerzo · tarifas propuestas: asesoría USD 55,00/h, programación USD 40,00/h, modelos USD 60,00/h, gestión USD 50,00/h · logística/IVA: reserva 25 % sobre hardware y complementos (a cotizar) · contingencia 10 %.

FASE 2 · A COTIZAR

Clúster de inferencia, almacenamiento distribuido para 5 TB y observatorio en tiempo real (Kafka/PostGIS).

Copiloto

RAG con citas

Dashboard

9 módulos

Modelo

Qwen3.5 adaptado

SOPORTE 12 MESES

USD 8.640,00 / año

18 % sobre servicios: monitoreo, actualizaciones, calidad y mesa de ayuda.

INVERSIÓN PRIMER AÑO

USD 73.607,38

MVP + 12 meses de soporte.

TARIFAS PROPUESTAS

Asesoría senior	**USD 55,00/h**
Programación	**USD 40,00/h**
Modelos IA	**USD 60,00/h**
Gestión y QA	**USD 50,00/h**

La logística/IVA es una reserva orientativa; se cotiza. No incluye licencias de terceros. Complementos y horas son estimaciones; la Fase 0 confirma alcance.

FASE 2

A cotizar: clúster, 5 TB distribuidos y observatorio en tiempo real.

Equipo: líder de proyecto · IA/RAG · IDP · dashboard · seguridad (parcial).

COSTO POR CONSULTA

USD 0,00 · sin cobro por token

ENERGÍA ESTIMADA

USD 157,68–183,96/año · 0,15 USD/kWh

DATOS

100 % locales · sin salida a internet

De la decisión al conocimiento consultable

Seis hitos. La Dirección solo necesita aprobar la Fase 0, designar una contraparte y facilitar el lote documental piloto.

00 — Aprobación
Semana 0

01 — Diagnóstico
Semanas 1–2

02 — Adquisición
Semanas 2–10

03 — Ingesta
Semanas 3–8

04 — Copiloto y dashboard
Semanas 8–13

05 — Capacitación y entrega
Semanas 13–16

CRONOGRAMA · 16 SEMANAS

ADQUISICIÓN EN PARALELO



Plazo total 16–24 semanas según importación y disponibilidad. **Fase 2 (mes 5+):** clúster de inferencia, observatorio en tiempo real y cobertura nacional.

Qué necesitamos de la Dirección

- Contraparte técnica con capacidad de decisión.
- Acceso al lote documental piloto y a los sistemas de origen.
- Espacio físico, red y punto de energía para el equipo.
- Validación jurídica del marco de confidencialidad y uso del dato.

La adquisición es el hito crítico: se recomienda iniciarla en paralelo a la Fase 0.

Decisión solicitada

Aprobar el alcance del MVP y autorizar el inicio de la Fase 0 (diagnóstico y definición del lote piloto).

- Aprobar el alcance del MVP
- Designar la contraparte técnica
- Autorizar el inicio de la Fase 0

La Fase 0 no requiere el hardware: puede comenzar de inmediato.

Aprobar la Fase 0 →

info@innovainteligente.com · WhatsApp +58 414-381-3674
innovainteligente.com · Propuesta confidencial

Sustento del MVP

Especificaciones verificadas en fuentes oficiales al 27/10/2026. Los precios son de tienda oficial, en USD y sin impuestos.

EQUIPO PROPUESTO · GMKTEC EVO-X5 PRO

DATO	VALOR
APU	AMD Ryzen AI Max+ PRO 495 · 16C/32T · Zen 5 · 5,2 GHz
GPU	Radeon 8065S · 40 CU RDNA 3.5
NPU	XDNA 2 · 55 TOPS · 132 TOPS totales
Memoria	192 GB LPDDR5X-8533 (8 × 24 GB) · 273 GB/s · 160 GB para GPU
Almacenamiento	2 TB NVMe + 3 ranuras adicionales M.2 · hasta 24 TB
Red	2×10 GbE (una con DASH) · Wi-Fi 7 · BT 5.4
Seguridad	dTPM 2.0 · AMD DASH · lector de huellas
Sistema operativo	Windows 11 Pro · soporte Linux/Ubuntu declarado
Consumo	120 W sostenidos / 160 W pico · fuente 330 W
Precio	**USD 6.799,00** (2 TB) · USD 7.099,00 (4 TB)
Garantía	1 año equipo + 2 años componentes
24/7	Sin declaración explícita; mini-PC profesional, no servidor certificado

196 GB: no existe como SKU. El máximo oficial es 192 GB (familia PRO 400). 192 GiB = 196.608 MiB; leer ese valor como MB y dividirlo entre 1.000 produce «196 GB». Hipótesis del origen de la cifra; se recomienda corregir el requisito a 192 GB.

ALTERNATIVAS EVALUADAS

EQUIPO	RAM	PRECIO	DISPONIBILIDAD
Framework Desktop DIY	192 GB	USD 6.799,00 sin SSD	Pre-orden dic-2026
Minisforum MS-S1 MAX-P495	192 GB	No encontrado	No disponible
Minisforum N5 MAX NAS	128 GB	USD 3.679,00	Envío nov-2026
GMKtec EVO-X3	128 GB	USD 3.799,99	En venta · 24/7

MODELOS LOCALES

MODELO	USO	MEMORIA
Qwen3.5-35B-A3B	Interactivo	22 GB
Qwen3.5-122B-A10B	Análisis profundo	81 GB
Qwen3-Embedding-8B	Embeddings	~16 GB
Qwen3-Reranker-8B	Reranking	~16 GB

Qwen3.5: 262.000 tokens de contexto · Apache-2.0 · 201 idiomas. DeepSeek V4.1-Flash (552B, ~310 GB) y R1 (671B, ~404 GB en Q4) no caben en 192 GB; se evalúan en una segunda etapa.

STACK DE SOFTWARE

Inferencia	Ollama / llama.cpp · vLLM para alta concurrencia
Vectorial	Qdrant
OCR / IDP	PaddleOCR + Tesseract · Qwen3-VL para páginas difíciles
Orquestación	Pipeline RAG propio sobre API local
Dashboard	Aplicación web a medida + API

Riesgos declarados: sin benchmark oficial en español; validar ROCm y VRAM en BIOS; importación no incluida; 10–20 usuarios con un nodo. Un Strix Halo es MVP/piloto, no producción nacional: 5 TB y concurrencia requieren clúster (aceleradores AMD Instinct + EPYC + almacenamiento distribuido).

Criterios de aceptación: 100 % del lote sin pérdida · respuestas con cita ≥ 95 % · latencia < 10 s · operación 100 % offline.

Fase 2 · escala nacional: nodos de inferencia con aceleradores AMD Instinct, servidores EPYC, almacenamiento distribuido (MinIO/Ceph), Kafka/PostGIS/TimescaleDB y orquestación Kubernetes. El Strix Halo queda como nodo piloto/edge.

PRECIOS
Oficiales al 27/10/2026, en USD y sin impuestos.

ALCANCE
10 láminas + 2 anexos técnicos.

CONTACTO
info@innovainteligente.com · +58 414-381-3674

Los 14 servicios, mapeados al MVP

Catálogo extraído de innovainteligente.com. El MVP activa siete servicios de forma directa; el resto queda como ruta de escalamiento.

MAPA DE SERVICIOS

#	SERVICIO	MOMENTO
01	RPA + IA	Fase 2
02	Procesamiento Inteligente de Documentos (IDP)	**MVP**
03	Optimización de cadena de suministro y operaciones	Fase 2
04	Integración de sistemas e interoperabilidad	**MVP**
05	Automatización de atención al cliente y ventas	Opcional
06	Desarrollo de modelos de IA a medida	Fase 2
07	Pruebas de concepto y prototipado rápido	**MVP**
08	Consultoría y gestión de fondos de I+D+i	No activado
09	Analítica predictiva y prescriptiva	Fase 2
10	Generación de propiedad intelectual	Fase 2
11	Auditoría de madurez digital y diagnóstico	**MVP · Fase 0**
12	Diseño de la hoja de ruta de IA	**MVP**
13	Gobernanza de datos y ética en IA	**MVP**
14	Capacitación y cambio cultural	**MVP**

Equipo y plazo: líder de proyecto · ingeniero de IA/RAG · especialista IDP/OCR · desarrollador de dashboard · especialista en seguridad (parcial). Implementación efectiva 12–14 semanas; total 16–24 semanas según importación. El MVP cubre un lote piloto; 5 TB y observatorio en tiempo real son fase 2.

FUENTES PRINCIPALES

AMD · ficha del Ryzen AI Max+ PRO 495 y blog del 12/10/2026 (“up to 192GB”).
GMKtec · EVO-X5 Pro, 192 GB / 2 TB, USD 6.799,00 (27/10/2026).
Framework · Desktop DIY 192 GB, pre-orden dic-2026.
Minisforum · MS-S1 MAX-P495 (sin precio) y N5 MAX 128 GB, USD 3.679,00.
Qwen · model cards Qwen3.5-35B-A3B, Qwen3.5-122B-A10B, Qwen3-Embedding-8B y Qwen3-Reranker-8B (Hugging Face).
DeepSeek · model card DeepSeek-V4.1-Flash-1017 (Hugging Face).
Ollama / Qdrant / PaddleOCR / vLLM · documentación oficial y licencias.
Innovainteligente · catálogo de 14 servicios y política de gobernanza de IA.

Nota de transparencia: los precios de HP Z2 Mini G1a, Lenovo ThinkCentre X Ultra y Minisforum MS-S1 MAX-P495 no se encontraron en fuentes oficiales y no se inventaron. El consumo eléctrico es una estimación; el costo real depende de la tarifa local.

Glosario: RAG recuperación aumentada · **OCR/IDP** lectura de papel y documentos · **LLM** modelo de lenguaje · **embeddings** representación vectorial · **RBAC** permisos por rol · **air-gap** operación aislada.

Documento preparado por Innovainteligente · 27/10/2026 · Confidencial. Los datos del dashboard son ilustrativos.

URLs de verificación

amd.com/en/products/processors/laptop/ryzen-pro/ai-max-pro-400-series/amd-ryzen-ai-max-plus-pro-495.html
gmktec.com/products/gmktec-evo-x5-pro-amd-ryzen-ai-max-pro-495-ai-mini-pc
huggingface.co/Qwen/Qwen3.5-35B-A3B · huggingface.co/Qwen/Qwen3.5-122B-A10B
innovainteligente.com/landing/

01
Aprobar la Fase 0 y designar contraparte.

02
Ejecutar el MVP en 16–24 semanas.

03
Escalar con RPA, analítica y segundo nodo.

ANEXO C · KPIS PROPUESTOS

Qué medir para gobernar la operación

22 indicadores para distribución, estaciones, mantenimiento, inventario, comercial e IA. La Dirección elige cinco por rol; el resto queda como tablero de detalle.

DISTRIBUCIÓN DE COMBUSTIBLE

KPI	DEFINICIÓN / FÓRMULA	FRECUENCIA
Volumen despachado	Litros o barriles despachados vs. meta	Diario
OTIF	% de entregas completas y a tiempo	Diario
Costo logístico / litro	Costo total de distribución ÷ litros	Mensual
Mermas y pérdidas	% sobre el volumen manejado	Semanal
Utilización de flota	% de capacidad de carga utilizada	Diario
Cobertura regional	Clientes y estaciones atendidas por región	Semanal

ESTACIONES DE SERVICIO

KPI	DEFINICIÓN / FÓRMULA	FRECUENCIA
Ventas por estación	Litros vendidos por día	Diario
Margen por litro	Precio de venta – costo de suministro	Diario
Quiebres de producto	% de horas sin inventario disponible	Diario
Ticket promedio	Ventas ÷ número de transacciones	Diario
NPS / satisfacción	Encuesta al cliente en estación	Mensual

MANTENIMIENTO

KPI	DEFINICIÓN / FÓRMULA	FRECUENCIA
Disponibilidad de flota	% del tiempo operativo de los vehículos	Diario
MTTR	Tiempo medio de reparación	Semanal
Cumplimiento preventivo	% del plan de mantenimiento ejecutado	Mensual
Costo de mantenimiento / km	Costo total ÷ kilómetros recorridos	Mensual

INVENTARIO Y COMERCIAL

KPI	DEFINICIÓN / FÓRMULA	FRECUENCIA
Días de cobertura	Inventario ÷ consumo diario promedio	Diario
Exactitud de inventario	% de diferencia física vs. sistema	Semanal
Contratos por vencer	Contratos que vencen en 30 / 60 / 90 días	Semanal
Margen por cliente	Margen bruto por cliente o contrato	Mensual

IA Y CONOCIMIENTO

KPI	DEFINICIÓN / FÓRMULA	FRECUENCIA
Latencia p95	Tiempo de respuesta del copiloto	Diario
Respuestas con cita	% con fuente validada	Semanal
Consultas y usuarios	Consultas/día y usuarios activos	Diario

DIRECCIÓN

Volumen vs. plan · OTIF · margen/litro · disponibilidad de flota · latencia IA.

OPERACIONES

Despacho · cobertura · mermas · quiebres · MTTR · días de inventario.

COMERCIAL

Ventas/estación · margen por cliente · contratos por vencer · NPS · cartera.

SELECCIÓN

Cinco KPI por rol; el resto queda en el tablero de detalle.

GOBIERNO

Un dueño por indicador y revisión mensual con la Dirección.

FINANCIERO

Añadir ingresos, margen bruto, EBITDA, capital de trabajo y costo por litro.